

潘星星



[这是方便打印的版本，良好排版请看 <https://paxinla.github.io/my-online-resume/cn/>]

☎ 137-9448-1350 | ✉ aksura@email.cn | 🔗 <https://paxinla.github.io>

期望职位：数据工程 | 期望薪资：面议 | 期望城市：深圳或远程

多年专业数据开发经验，熟悉数据处理全流程，包括数据清洗、数据存储、解决各种数据问题（数据堆积、数据延迟、数据传输效率等）。主要工作领域为企业级数据仓库的设计实施、海量数据的 ETL 加工处理、数据处理平台的设计建设、联机数据库架构的设计/实施/维护、SQL 性能调优等，在项目中高效地合作与协调。为大型商业银行设计并实施过完整的数据仓库项目，也为互联网企业落地过大数据平台方案。

曾服务过的行业包括传统IT、互联网、AI 公司等，喜欢严谨务实的团队，期望能加入业务有长远发展谋划、致力于持续为社会创造价值的企业。

技术栈

🔧 主要技术栈

- ➔ Python/Scala : ★★★★★
- ➔ OLAP 数据仓库/数据治理/建模集成/ETL : ★★★★★
- ➔ OLTP 数据库方案设计优化 : ★★★★★☆
- ➔ 离线海量数据处理方案设计落地 : ★★★★★☆

🔧 涉猎

- ➔ 其他常用语言：SQL、Bash、Clojure
- ➔ 其他常用工具：PostgreSQL、Hadoop/Spark、RabbitMQ、MongoDB、Kettle

> 资格证书

- 🏆 PMP | Project Management Professional
- 🏆 OCP 11g | Oracle Certified Professional 11g
- 🏆 软件设计师 | 计算机技术与软件专业技术资格(水平)

> 教育经历

- 🎓 2008年~2012年7月 重庆邮电大学 计算机科学与技术 - 本科
- 🎓 2008年~2012年7月 重庆邮电大学 通信工程 - 本科二专业

> 工作经历

1. 深圳市星航科技有限公司 -- Data Engineer , 3年, 自 2021 起
2. 八斗智能科技(广州)有限公司 -- Data Engineer , 1年, 自 2019 起
3. 深圳爱拼信息科技有限公司 -- Data Engineer , 3年, 自 2015 起
4. 深圳四方精创资讯股份有限公司 -- 研发级DBA , 3年, 自 2012 起

【2021.10 - 2025.01】 云原生数据湖仓 项目

- Lakehouse | Spark/Databricks | Great Expectations

该项目建立并持续增强一个大规模的 Web3 领域的湖仓一体系统，为公司研究团队、各 Web3 产品提供了强大的数据支撑。

我在这个项目中负责的工作有：

1. 结合公司的业务，设计、规划与实施现代化湖仓与服务设施。
2. 分析并构建合理的数据模型与 ETL 流程等，持续建设与改进高性能数据服务。
3. 参与业务的数据调研、分析，满足产品的数据需求，支撑部分业务决策。
4. 总结与维护技术文档，推动发展优质产品。

这个由我负责的企业级别的湖仓系统，是基于 Databricks on AWS 的云原生方案而构建的。它采用 Databricks 完成从研究性分析到生产数据的全部处理过程，用 Great Expectations 作数据质量检查和监控。这个湖仓完全摆脱了陈旧的 Hadoop 生态工具，在管理多样形态的数据和处理数据的性能方面的表现要优越得多。这个方案在并未增加供应商绑定的风险的同时，极大地降低了公司需要投入的物理基础设施成本和运维成本。我使用该湖仓集成并处理了来自区块链上日均约百万行和智能合约的原始数据，高效地为公司的各个 Web3 数据产品的和数据科学家团队提供了高质量的数据。

【2016.08 - 2019.01】 产品联机数据库管理

- PostgreSQL | 阿里云 | 数据库集群

该项目为公司核心产品“X志愿”的联机数据库，部署在阿里云上，可靠地支撑了产品的数据管理需求。

我在这个项目中负责的工作有：

1. 负责开发、测试、生产等所有环境的数据库系统架构的设计、实施、日常操作、配置、监控及故障处理。负责监控备份情况、恢复策略方案的制定与数据备份恢复计划的制定、执行。
2. 负责数据库性能监控和调优，监控并及时发现问题，优化后台对数据库的访问方式、性能较差的 SQL。
3. 负责项目中的数据库逻辑结构设计。分析业务需求，设计审核并创建维护数据库对象。
4. 根据业务需求批量生成/更新产品所需的核心数据集，维护它们的质量。
5. 对数据库相关的故障和性能问题及时定位问题并解决问题。

“X志愿”是公司的核心数据产品之一，它依托全国大专院校历年的招生录取数据及 AI 算法，根据高考考生的自身情况，预测目标学校专业的当年录取情况，给考生个性化的填报志愿的智能建议。公司为百度 App 中全国唯三的志愿填报服务提供商之一。

公司采用的云服务商是阿里云，生产环境都部署在阿里云上。我全权负责该产品的数据库架构的设计与实施。

公司在考察了阿里云 RDS 的性能与稳定性后，综合考虑了价格、“X志愿”产品的数据访问特征、整个产品对数据库的性能及稳定的要求等因素，选择了在 ECS 上自建基于 PostgreSQL 的生产数据库集群。我设计并落地了数据库集群架构方案。集群全年无故障稳定运行。与之前该产品上一代基于 MongoDB 的数据库方案相比，在读写性能、开发灵活性、功能的丰富程度、批量更新数据的效率及服务稳定性上都有了明显地改善。我为该集群实现了备份策略实施自动化，保障了产品数据的安全。业务系统对数据库的访问及业务基础数据的增长在每年高考前后一段时间内，都会剧增；而其他时间段的负载则较为平稳。如果为以能处理这类峰值访问为标准来投入资源随时待命无疑是巨大的浪费。因此，我设计了集群在业务高峰时期前后能平滑地扩容、缩容的方案。集群在业务高峰时，平稳支撑过 TPS 约 8k；在高峰时段外，则以经济的方式稳定支持业务。

【2015.11 - 2018.11】 求职就业领域的数据仓库 项目

- 数据仓库 | Hadoop | PostgreSQL

该项目为公司的数据基础设施之一，为 AI 算法团队的数据科学家和数据挖掘工程师提供稳定质量的数据支持及海量数据处理的技术支持。

我在这个项目中负责的工作有：

1. 负责大数据平台的核心数据仓库和数据集市的建设，包括开发规范、维度建模、质量指标规范。
2. 带领团队成员处理数据，包括数据清洗、量化、集成、存储等。
3. 规划大数据平台的技术方案并实施。
4. 为 AI 算法团队提供处理海量数据的技术支持。

该项目属于公司基础数据设施的重要组成部分，集成了数据采集团队获得的多年求职就业领域的的数据。主要用来为公司 AI 算法团队的数据科学家和数据挖掘工程师提供数据集，并将他们的产出模型应用到存量数据(约30TB)上获得结果，以供公司的数据产品使用。并周期性批量生成大专院校的就业统计数据报告，供公司的拳头产品“XX志愿”使用。

在这个项目中，我带领数据开发团队，根据公司数据战略的目标及就业领域的数据的特点，设计并落地了基于 CDH 和 PostgreSQL 来构建数据仓库的方案。综合使用了 Pentaho Data Integration 、DataX 、Hive 、MapReduce 、Spark 等组件构建了 ETL 及 data pipeline ，构建基于 Apache Airflow 的作业调度系统。用集中的自动化调度及监控替代了公司过去遗留的分散的应激式数据转换作业。比如，原先一个需运行耗时约一周的全量计算作业，在新平台上的耗时缩短到约1.5天。

【2013.06 - 2015.08】 特色业务装载平台 项目

- 调度 | 海量数据ETL

该项目为某国有大型商业银行深圳分行各特色应用系统实现 ETL 过程及调度的一个平台，它根据下游各业务系统的需要，定制加工并输送来自异构数据源的数据到业务系统的联机库。

我在这个项目中负责的工作有：

1. 负责对该平台的核心调度程序及作业程序进行维护及二次开发。
2. 设计、维护该平台对于总行下传数据文件、特色系统数据库中数据的 ETL 过程。在平台发生故障时及时处理。
3. 根据不同特色应用系统用户提出的新需求，为其定制 ETL 过程，监控、保障每日批量作用的成功完成。
4. 根据特色应用系统用户的要求，协助对其实施历史数据的追取。

这个项目涉及的数据源是多个异构的，属于其他组织的系统，目的地则是许多不同部门的特色业务系统应用层数据集市及联机数据库，对批量作业的执行时效有一定的要求。在我接手该项目后，完成了对大部分已有的历史作业程序的改造，提高了这些作业程序的容错性和平台自动处理错误的能力。

例如，平台的数据源中有一张记录数约为4000万的账户表，是许多下游目标系统的数据来源。它会在每季度结息日数据量剧增，导致其装载作业(merge模式)运行时间过长且容易失败，过去常需人工到现场监控处理。我在接手后，针对该表的 ETL 过程，通过对数据源文件的自动拆分切片、分析增量变更、合并到存量快照表的方式优化。提高了整体数据装载的效率及自动化程度，使得该作业不论在结息日还是平日的运行时间均保持稳定、工作正常。

【2013.07 - 2014.12】 海外分行监管报表 项目

- 需求分析 | 数据仓库

该项目为某国有大型商业银行欧洲某分行建设的监管报表数据仓库。可按当地监管部门的数据和格式要求出具监管报表所需数据文件；为该分行的客户出具固定格式的各类用户报表；为该分行的业务部门提供内部分析报表。

我参与了该项目从需求分析到部署维护的完整过程，负责的工作有：

1. 需求分析阶段，协助项目经理与业务部门沟通、明确需求、规划元数据，参与了所有项目文档的编撰。
2. 开发测试阶段，设计表结构和数据处理程序，完成开发和测试的工作。
3. 部署上线阶段，在数据中心现场独立支持项目版本部署实施，为运维工程师制定、实施数据备份策略。
4. 维护阶段，提供远程技术支持服务。

项目中，我们数据团队发现该海外分行使用的外购资金业务处理系统 Murex 的后台数据的结构与该银行其他系统的结构差异很大，需要较多的集成工作；且海外分行有许多国内没有的业务类型，比以往我们处理国内的银行业务逻辑更为复杂。经过我与团队同事的集智努力，在项目第一期SIT测试前，我们理清了该海外分行关注的业务的转换处理规则，明确约束了需求的范围。对其外购资金业务处理系统的后台数据进行了多重的处理，最终使这块业务的监管报表数据得以顺利集成完毕，满足了所有相关报表的计算需求，我们的技术能力及数据质量得到了该海外分行的认可。

项目投产阶段，我作为数据开发团队的工程师代表，与整个深圳开发团队到总行北京数据中心参与投产过程。在总行运维团队上线系统的过程中，发生了因生产环境问题导致相关批量调度系统未顺利启动的情况。我作为在现场唯一的数据开发团队成员，在计划投产时间点迫近及总行团队领导在场的压力下，成功分析、定位到问题发生的原因，并及时解决。保证了系统及时正常地上线。

【2013】 对私客户历史交易查询系统 项目

- ETL | Oracle

该项目为某国有大型商业银行深圳分行的对私客户历史交易查询系统。从异构数据源整合历史交易流水数据，满足该行所有支行的柜台及零售部门对私客户的交易历史查询需求。

我在这个项目中负责的工作有：

1. 分析业务需求，进行 Oracle 数据库建模设计。
2. 开发 ETL 程序将异构数据源中的历史交易数据清洗转换、迁移并装载到该系统的数据库中。
3. 开发 ETL 程序将每日新的增量交易流水数据清洗并装载到该系统的数据库中。
4. 为系统后台查询数据库部分开发、调优查询接口服务。

这个项目是该分行面向所有对私客户交易数据的查询平台，交易数据的历史经历了3代核心系统，故不同代际系统的交易数据的结构有较大差异。历史的数据是从磁带库的备份中导出的文件，新发生的数据是总行周期性下发的定制化结构文件。在我参与该项目时，存量数据约有15亿左右的记录，并以每天100万的速度增长。

我在项目中的主要作用有，在项目初期完成了对3代系统的数据的原始结构分析、新结构的规范化、数据表建模的工作；我处理历史磁带存量交易数据文件(约20年)时，编写解析数据文件、转换数据的程序，并将其装载入库，约两日完成工作。在项目后期对查询接口服务进行优化，融合查询接口服务以 Oracle 的包形式提供给后台系统使用，优化前查询时间有时近秒级，优化后查询平均时间稳定为微秒级。

致 谢

非常感谢您花时间阅读我的简历，期待能有机会和您共事。